

Kimi-K3供应商接入自测指导

目的：在正式接入前，供应商需按本指导完成 **功能** 与 **性能** 两类自测，并回传结果。测试通过是接入的前置条件。

接口标准：OpenAI 兼容的 `/v1/chat/completions`（含流式 SSE）。

本指导基于既有评测框架（功能用例 22 项 + Benchmark 压测）整理。

一、测试范围总览

类别	子项	用例数	是否必过
功能 · 协议完整性	Stream 完整性、Usage 字段（流式/非流式）	3	是
功能 · 多模态图像	Image_url、Image_base64	2	最少支持Image_base64
功能 · 多模态视频	Video_url、Video_base64	2	最少支持Video_base64
功能 · 工具调用支持	Tool Call 能力	1	是
功能 · 工具调用检测	Tool Choice： Auto/Required/Function/Allowed_tools/None/Default	6	Function可不过（官方不支持）
功能 · 思考行为	4 种思考开关 + 默认思考	5	模型默认思考，支持思考开关（支持其中一种就可以） "enable_thinking": false, "chat_template_kwargs": {"enable_thinking": false}, "chat_template_kwargs": {"thinking": false}, "thinking": {"type": "disabled"},
功能 · 结构化输出		2	是

	JSON Schema、JSON Object		
<code>reasoning_effort</code> 推理强度	Low high max	3	是
功能 · 连通性	基础连通性	1	是
性能 · 压测（平均 32k输入和 300输出）	吞吐 / TTFT / Latency / TPOT / ITL / 缓存命中	—	是

二、功能测试

2.1 通用要求

- **通过判定**：每个用例通过率需达 **100%**，HTTP 状态码为 **200**。
- **协议一致性**：请求/响应结构必须符合 OpenAI Chat Completions 规范，字段名、层级、类型不得偏移。
- **每个用例需回传**：HTTP 状态码、耗时（ms）、完整请求体与响应体（或流式分片）。

2.2 协议完整性检测（必过，3 项）

用例	检查点
Stream 完整性	<code>stream:true</code> 时须持续返回 SSE 分片（≥2 片），并以 <code>[DONE]</code> 正常结束，无中途断流或网关截断
Usage 字段 · 非流式	响应含 <code>usage</code> ，且 <code>prompt_tokens</code> / <code>completion_tokens</code> /

	<code>total_tokens</code> 均存在且合理
Usage 字段 · 流式	流式模式下最终仍能拿到 <code>usage</code> 统计（未包或 <code>stream_options.include_usage</code> <code>_usage</code> ）

样例请求（Stream 完整性）

Code block

```
1  {
2    "messages": [{ "role": "user", "content": "请用中文写一句关于春天的话。" }],
3    "model": "<your-model-id>",
4    "stream": true
5  }
```

预期：HTTP 200，收到多个 `chat.completion.chunk`，最终 `[DONE]`。

2.3 多模态检测（视能力声明，图像 2 + 视频 2）

用例	检查点
Image_url	<code>content</code> 数组中含 <code>image_url</code> （远程 URL），模型能正确理解并作答
Image_base64	<code>image_url</code> 以 <code>data:image/...;base64</code> ，形式传入，能正确解析
Video_url	支持视频 URL 输入并理解内容
Video_base64	支持视频 base64 输入并理解内容

注意：多模态用例耗时通常较高（数十秒级），请确保网关超时阈值足够。

2.4 工具调用（能力 1 + 检测 6）

需验证 `tools` 与 `tool_choice` 全部取值分支：

tool_choice 取值	期望行为
(不传) Default	模型自行决定是否调用工具
auto	模型自行决定，可调用可不调
required	必须发起至少一次工具调用
none	禁止工具调用，只返回文本
{ "type": "function", "function": { "name": "..."} }	强制调用指定函数
allowed_tools	仅允许在给定的工具子集内选择

样例请求（Tool Choice Function）

```
Code block
1  {
2    "model": "<your-model-id>",
3    "messages": [{ "role": "user", "content": "北京今天天气怎么样? " }],
4    "tools": [{
5      "type": "function",
6      "function": {
7        "name": "get_weather",
8        "parameters": {
9          "type": "object",
10         "properties": { "city": { "type": "string" } },
11         "required": ["city"]
12       }
13     }
14   ]
15 }
```

```
14     ]],
15     "tool_choice": { "type": "function", "function": { "name": "get_weather" } }
16 }
```

预期：HTTP 200，响应 `tool_calls` 中包含对 `get_weather` 的调用及合法 JSON 参数。

2.5 思考行为检测（视能力声明，5 项）

若模型支持思考/推理链，需验证以下开关均能正确控制思考输出的开启与关闭：

用例	参数
enable_thinking	<code>enable_thinking:</code> <code>true/false</code>
thinking.type	<code>thinking:</code> { "type": "enabled"/"disabled" }
chat_template_kwargs.enable_thinking	<code>chat_template_kwargs:</code> { "enable_thinking": ... }
chat_template_kwargs.thinking	<code>chat_template_kwargs:</code> { "thinking": ... }
默认思考	不传任何开关时的默认行为需符合声明

检查点：开关为「开」时返回 `reasoning_content`（或等价字段）；为「关」时不应包含思考内容。

2.6 结构化输出检测（必过，2 项）

用例	检查点

JSON Schema	<code>response_format: { "type": "json_schema", ... } , 输出严格符合给定 schema</code>
JSON Object	<code>response_format: { "type": "json_object" } , 输出为合法可解析 JSON</code>

2.7 连通性检测（必过，1 项）

基础单轮请求返回 200 且内容合理，作为链路最小可用性验证。

2.8 推理强度（reasoning_effort）

若支持 `reasoning_effort`，需验证 `low / high / max` 三档随强度递增，思考 token 消耗有可观测的区分度：

- 提交同一问题（示例：用 1、2、3、4、5 各一次组成能被 11 整除的五位数），分别用三档取值请求。

- 回传各档 `reasoning_tokens`，确认参数生效（至少 low 与 high 有明显差异）。

三、性能测试

3.1 压测方法

- 工具：MTB Benchmark（或等价的多轮会话压测工具）。
- 场景：模拟真实多轮长上下文对话，TPM 匀速爬坡至目标稳态后持续压测。
- 数据集：ShareGPT 类多轮对话数据。

参考参数（平均 32k 输入和 300 输出）

```
code block
2      --total-sessions <会话数>
3      --arrival-rate-start 0.08
4      --arrival-rate-end 1
5      --ramp-duration-seconds 600
6      --num-rounds 'avg=30.2,p50=25.0,p75=34.0,p90=47.0,p95=57.0'
7      --turn-interval 'avg=18.6,p50=4.0,p75=10.0,p90=35.0,p95=86.0'
8      --init-prompt-length 'avg=28568.9,p50=21983.0,p95=74262.9'
9      --input-length 'avg=1352.6,p50=493.0,p95=4740.0'
10     --output-length 'avg=345.8,p50=68.0,p95=1514.0'
```

3.2 需回传的指标

指标	说明
Total requests / Duration	总请求数、压测时长
Throughput	请求吞吐（req/s）、输入 tok/s、输出 tok/s
TTFT	首 token 时间：avg / p50 / p75 / p90 / p95 / p99
Latency	端到端延迟：avg / p50 / p75 / p90 / p95 / p99
TPOT	每输出 token 耗时：avg 及各分位
ITL	token 间延迟：avg 及各分位
Cache hit rate	整体缓存命中率，及分轮次命中率

3.3 参考基线

以下为既有评测中观测到的量级，供应商结果应在同一数量级、无明显劣化：

指标	参考区间
请求吞吐	≥ 0.6 req/s（视目标 TPM 而定）
TTFT P50	≤ 15 s（长上下文场景）
TPOT P50	<35 ms
缓存命中率（稳态轮次）	≥ 60%

稳态提示：首轮（Round 0）无历史，缓存命中率接近 0 属正常；进入多轮后命中率应显著上升。若始终偏低，需排查 Prefix Cache 是否生效。

四、结果回传要求

供应商需提交一份自测报告，包含：

- 1. 环境信息：模型 ID、API 端点、测试日期。
- 2. 功能测试结果表：22 项用例逐条列出「通过率 / HTTP 状态 / 耗时 / 结论」，失败项须附请求体、响应体与失败原因。
- 3. 性能测试结果：完整的 Benchmark 输出（吞吐、TTFT、Latency、TPOT、ITL、缓存命中及分轮次明细）。
- 4. 能力声明与豁免说明：不支持的可选能力（多模态、思考、reasoning_effort 等）需明确说明。

验收标准

- 所有「必过」用例通过率 100%、HTTP 200。
- 声明支持的能力，其对应用例必须全部通过。
- 性能指标与参考基线处于同一数量级，无明显劣化。
- 任一必过项失败即视为自测未通过，修复后需重测并回传。

